Markov decision process
إجراءات ماركوف لاتخاذ القرار

خاصية ماركوف هي سمة "انعدام الذاكرة" للعمليات العشوائية، أي أن احتمالية الحالات المستقبلية تعتمد فقط على الحالة الحالية، وليس على التاريخ الكامل أو تسلسل الأحداث التي أدت إليها، كما لو أن النظام "ينسى" ماضيه أثناء تقدمه. وهي خاصية أساسية لسلاسل ماركوف (الزمن المتقطع) وعمليات ماركوف، إذ تُبسط التنبؤات بالتركيز فقط على الحالة الحالية لحساب الاحتمالات المستقبلية، مما يجعل المستقبل مستقلاً عن الماضي، بالنظر إلى الحاضر. $P[S_{t+1} \mid S_t] = P[S_{t+1} \mid S_1, \ldots, S_t]$

في نظرية الاحتمالات والإحصاء، تُعرف سلسلة ماركوف أو عملية ماركوف بأنها عملية عشوائية تصف سلسلة من الأحداث المحتملة، حيث يعتمد احتمال كل حدث فيها فقط على الحالة التي تم الوصول إليها في الحدث السابق. ويمكن التعبير عن ذلك ببساطة على النحو التالي: "ما سيحدث لاحقًا يعتمد فقط على الوضع الراهن". وتُسمى السلسلة المتقطعة الزمن (DTMC) بسلسلة ماركوف المنفصلة قابلة للعد، حيث تنتقل السلسلة بين الحالات بخطوات زمنية منفصلة. أما العملية المستمرة الزمن فتُسمى سلسلة ماركوف المستمرة الزمن (CTMC). وقد سُميت عمليات ماركوف تكريمًا لعالم الرياضيات الروسي أندريه ماركوف.

لسلاسل ماركوف تطبيقات عديدة كنماذج إحصائية لعمليات العالم الحقيقي. فهي تُشكل الأساس لأساليب المحاكاة العشوائية العامة، وقد وجدت تطبيقات في مجالات تشمل الإحصاء، وعلم الأحياء، والكيمياء، والاقتصاد، والتمويل، ونظرية المعلومات، والفيزياء، ومعالجة الإشارات، ومعالجة الكلام.

التعريف

عملية ماركوف هي عملية عشوائية تحقق خاصية ماركوف (التي تُوصف أحيانًا بأنها "انعدام الذاكرة"). بعبارة أبسط، هي عملية يمكن التنبؤ بنتائجها المستقبلية بناءً على حالتها الراهنة فقط، والأهم من ذلك، أن دقة هذه التنبؤات تضاهي دقة التنبؤات التي يمكن إجراؤها بمعرفة تاريخ العملية بالكامل.

التعريفات

- سلسلة ماركوف هي العملية X0، X1، X2، ...
- التعريف: حالة سلسلة ماركوف عند الزمن t هي قيمة Xt .
- على سبيل المثال، إذا كانت Xt = 6، نقول إن العملية في الحالة 6 عند الزمن t .
- التعريف: فضاء الحالة لسلسلة ماركوف، S، هو مجموعة القيم التي يمكن أن تأخذها كل قيمة Xt .
- على سبيل المثال، S = {1, 2, 3, 4, 5, 6, 7}.
- التعريف: مسار سلسلة ماركوف هو مجموعة محددة من قيم X0، X1، X2، ...
- على سبيل المثال، إذا كانت X0 = 1، X1 = 5، وX2 = 6، فإن المسار حتى الزمن t = 2 هو 1، 5، 6.

بشكل أعم، إذا أشرنا إلى المسار s0، s1، s2، s3، ...، فإننا نعني أن: X0 = s0، X1 = s1، X2 = s2، X3 = s3، ... "المسار" هو ببساطة كلمة تعني "الطريق".

خاصية ماركوف

الخاصية الأساسية لسلسلة ماركوف هي أن النقطة الأخيرة فقط في المسار تؤثر على ما يحدث لاحقًا. تُسمى هذه الخاصية بخاصية ماركوف. وهذا يعني أن Xt+1 تعتمد على Xt ولا تعتمد على Xt−1، ...، X1، X0 .

يمكن صياغة خاصية ماركوف رياضيًا كما يلي:

$$\boxed{\mathbb{P}(X_{t+1} = s \,|\, X_t = s_t, X_{t-1} = s_{t-1}, \ldots, X_0 = s_0) \;=\; \mathbb{P}(X_{t+1} = s \,|\, X_t = s_t).}$$

for all $t = 1, 2, 3, \ldots$ and for all states $s_0, s_1, \ldots, s_t, s$.

توضيح:

$$\underset{\substack{\uparrow \\ \textit{distribution} \\ \textit{of } X_{t+1}}}{\mathbb{P}(X_{t+1} = s} \;\Big|\; \underset{\substack{\uparrow \\ \textit{depends} \\ \textit{on } X_t}}{X_t = s_t}, \; \underbrace{\cancel{X_{t-1} = s_{t-1}, X_{t-2} = s_{t-2}, \ldots, X_1 = s_1, X_0 = s_0)}}_{\substack{\uparrow \\ \textit{but whatever happened before time } t \\ \textit{doesn't matter.}}}$$

Markov Process: Overview

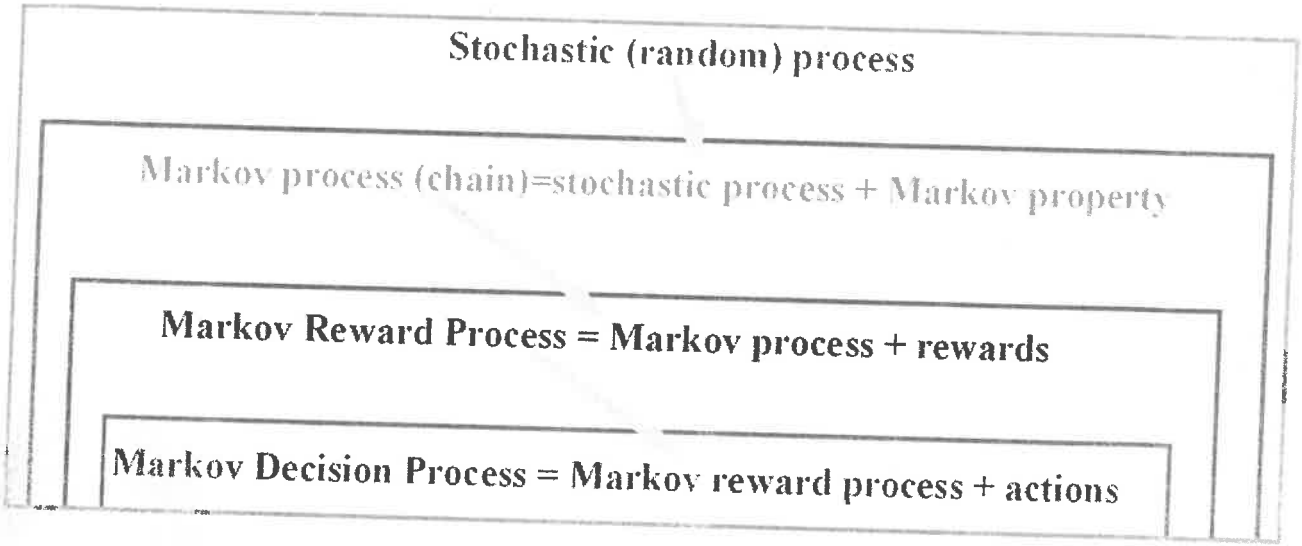

مصفوفة الانتقال

Transition Matrix

$$
\begin{array}{c|c}
 & \overbrace{\qquad\qquad\qquad}^{X_{t+1}} \\
 & \text{list all states} \\
X_t \left\{ \begin{array}{c} \text{list} \\ \text{all} \\ \text{states} \end{array} \right. & \begin{pmatrix} \texttt{insert} \\ \texttt{probabilities} \\ p_{ij} \end{pmatrix} \begin{array}{l} \longleftarrow \text{rows add to 1} \\ \longleftarrow \text{rows add to 1} \end{array}
\end{array}
$$

يُرمز لمصفوفة الانتقال عادةً بالرمز P = (pij).

في مصفوفة الانتقال :P

- تمثل الصفوف الحالة الحالية اومن Xt،
- تمثل الأعمدة الحالة التالية اوالى Xt+1؛
- العنصر (i,j), هو الاحتمال الشرطي أن تكون الحالة التالية هي الحالة j، بشرط أن تكون الحالة الحالية هي الحالة i أي احتمال الانتقال من الحالة i إلى الحالة j.

$$\boxed{p_{ij} = \mathbb{P}(X_{t+1} = j \mid X_t = i).}$$

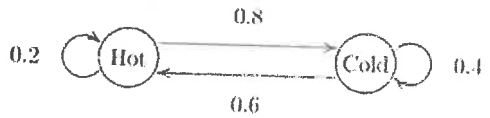

مخطط الانتقال لوصف سلاسل ماركوف موضح في الشكل أعلاه.

يُطلق على مخطط الانتقال هذا الاسم لأنه يُظهر الانتقالات بين الحالات المختلفة.

يمكننا أيضًا تلخيص الاحتمالات في مصفوفة:

تُسمى المصفوفة التي تصف سلسلة ماركوف بمصفوفة الانتقال.

وتعتبر مهمة لتحليل سلاسل ماركوف.

$$
\begin{array}{c|cc}
 & \multicolumn{2}{c}{\overbrace{\qquad\qquad}^{X_{t+1}}} \\
 & \text{Hot} & \text{Cold} \\
X_t \left\{ \begin{array}{c} \text{Hot} \\ \text{Cold} \end{array} \right. & \multicolumn{2}{c}{\begin{pmatrix} 0.2 & 0.8 \\ 0.6 & 0.4 \end{pmatrix}}
\end{array}
$$

- A particular *sequence of states* of length T is denoted by

$$\mathcal{W}^T = \{w(1), w(2), \ldots, w(T)\}.$$

- The model for the production of any sequence is described by the *transition probabilities*

$$a_{ij} = P(w(t) = w_j | w(t-1) = w_i)$$

where $i, j \in \{1, \ldots, N\}$, $a_{ij} \geq 0$, and $\sum_{j=1}^{N} a_{ij} = 1$.

- **كيفية العمل (مثال: الطقس)**
- تحديد الحالات: مشمس، ممطر، ضبابي.

1. تقدير الاحتمالات: بناءً على البيانات التاريخية، يتم تحديد ما يلي:
2. احتمال (مشمس | مشمس) = 0.8، احتمال (ممطر | مشمس) = 0.1، وهكذا.
3. احتمال (مشمس | ممطر) = 0.3، احتمال (ممطر | ممطر) = 0.40، وهكذا.
4. التنبؤ: إذا كان الطقس مشمسًا اليوم، فإن احتمالات الطقس غدًا تُعطى بواسطة صف "مشمس" في المصفوفة (0.8، 0.05، 0.15).

- Consider the following 3-state first-order Markov model of the weather in Ankara:
  - w_1: rain/snow
  - w_2: cloudy
  - w_3: sunny

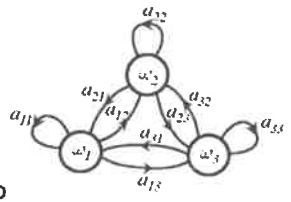

$$\Theta = \{a_{ij}\} = \begin{array}{c|ccc} & \text{To} & & \\ \text{From} & \text{W1} & \text{w2} & \text{w3} \\ \hline \text{W1} & 0.4 & 0.3 & 0.3 \\ \text{W2} & 0.2 & 0.6 & 0.2 \\ \text{W3} & 0.1 & 0.1 & 0.8 \end{array}$$

First-Order Markov Model Examples

- We can use this model to answer the following: Starting with sunny weather on day 1 (given), what is the probability that the weather for the next seven days will be "sunny-sunny-rainy-rainy-sunny-cloudy-sunny" ($\mathcal{W}^8 = \{w_3, w_3, w_3, w_1, w_1, w_3, w_2, w_3\}$)?
- Solution:

$$
\begin{aligned}
P(\mathcal{W}^8|\Theta) &= P(w_3, w_3, w_3, w_1, w_1, w_3, w_2, w_3) \\
&= P(w_3)P(w_3|w_3)P(w_3|w_3)P(w_1|w_3) \\
&\qquad P(w_1|w_1)P(w_3|w_1)P(w_2|w_3)P(w_3|w_2) \\
&= P(w_3)\, a_{33}\, a_{33}\, a_{31}\, a_{11}\, a_{13}\, a_{32}\, a_{23} \\
&= 1 \times 0.8 \times 0.8 \times 0.1 \times 0.4 \times 0.3 \times 0.1 \times 0.2 \\
&= 1.536 \times 10^{-4}
\end{aligned}
$$

$$
\begin{array}{cc}
 & \text{To} \\
 & \begin{array}{ccc} \text{W1} & \text{w2} & \text{w3} \end{array} \\
\text{From} \begin{array}{c} \text{W1} \\ \text{W2} \\ \text{W3} \end{array} & \begin{pmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{pmatrix}
\end{array}
$$

First-Order Markov Model Examples

- Consider another question: Given that the model is in a known state, what is the probability that it stays in that state for exactly d days?
- Solution:

$$\mathcal{W}^{d+1} = \{w(1) = w_i, w(2) = w_i, \ldots, w(d) = w_i, w(d+1) = w_j \neq w_i\}$$

$$P(\mathcal{W}^{d+1}|\Theta, w(1) = w_i) = (a_{ii})^{d-1}(1 - a_{ii})$$

$$E[d|w_i] = \sum_{d=1}^{\infty} d\,(a_{ii})^{d-1} \Big/ (1 - a_{ii}) = \frac{1}{1 - a_{ii}}$$

- For example, the expected number of consecutive days of sunny weather is 5, cloudy weather is 2.5, rainy weather is 1.67.

$$
\begin{array}{cc}
 & \text{To} \\
 & \begin{array}{ccc} \text{W1} & \text{w2} & \text{w3} \end{array} \\
\text{From} \begin{array}{c} \text{W1} \\ \text{W2} \\ \text{W3} \end{array} & \begin{pmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{pmatrix}
\end{array}
$$

PROBABILITY AND STATISTICS : MARKOV CHAINS (2) INTRODUCTION (OTHER METHOD)

$$\begin{bmatrix} A_1 \\ B_1 \\ C_1 \end{bmatrix} = \begin{array}{c} \text{FROM} \\ \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \end{array} \text{TO} \begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix}$$

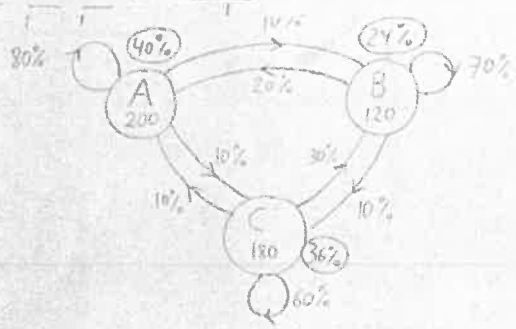

$$[A_1\ B_1\ C_1] = \begin{array}{c} \text{CURRENT STATE} \\ \begin{bmatrix} 0.40 & 0.24 & 0.36 \end{bmatrix} \end{array} \begin{array}{c} \text{FROM} \\ \begin{bmatrix} A & B & C \\ 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \end{array} =$$

$$= \left[(0.4)(0.8) + (0.24)(0.2) + (0.36)(0.1) \right]$$

$$\left[(0.4)(0.1) + (0.24)(0.7) + (0.36)(0.3) \right]$$

$$\left[(0.4)(0.1) + (0.24)(0.1) + (0.36)(0.6) \right]$$

$$= \begin{bmatrix} 0.404 & 0.316 & 0.280 \end{bmatrix}$$

NEXT (FUTURE STATE)

PROBABILITY AND STATISTICS . MARKOV CHAINS (1) INTRODUCTION

$$[\text{NEXT STATE}] = \begin{bmatrix} \text{MATRIX OF} \\ \text{TRANSITION} \\ \text{PROBABILITIES} \end{bmatrix} [\text{CURRENT STATE}]$$

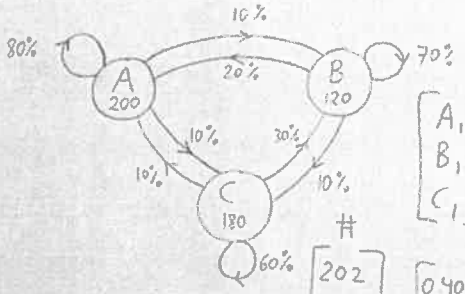

$$X_1 = P X_0$$

$$\begin{bmatrix} A_1 \\ B_1 \\ C_1 \end{bmatrix} = \begin{array}{c} \text{FROM} \\ \begin{array}{ccc} A & B & C \end{array} \\ \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \end{array} \begin{array}{c} A \\ B \\ C \end{array} \text{TO} \begin{bmatrix} A = 200 \\ B = 120 \\ C = 180 \end{bmatrix} \begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix}$$

$$\begin{array}{c} \# \\ \begin{bmatrix} 202 \\ 158 \\ 140 \end{bmatrix} \end{array} = \begin{array}{c} \begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix} \\ 1.000 \checkmark \end{array} = \begin{bmatrix} (0.8)(0.4) + (0.2)(0.24) + (0.1)(0.36) \\ (0.1)(0.4) + (0.7)(0.24) + (0.3)(0.36) \\ (0.1)(0.4) + (0.1)(0.24) + (0.6)(0.36) \end{bmatrix}$$

TOTAL = 500 ✓

PROBABILITY AND STATISTICS : MARKOV CHAINS (3) WHY THEY CALL IT CHAINS

$$X_1 = P X_0 \qquad X_2 = P X_1 \qquad X_3 = P X_2 \quad \ldots$$

NEXT STATE (STATE 1) — PROBABILITY MATRIX — INITIAL STATE

$$\begin{aligned} A &= 200 \\ B &= 120 \\ C &= 180 \\ \hline & \ 500 \end{aligned}$$

$$X_1 = \begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix} = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix}$$

$$X_2 = \begin{bmatrix} 0.414 \\ 0.346 \\ 0.240 \end{bmatrix} = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix} = \begin{bmatrix} (0.8)(0.404) + (0.2)(0.316) + (0.1)(0.280) \\ (0.1)(0.404) + (0.7)(0.316) + (0.3)(0.280) \\ (0.1)(0.404) + (0.1)(0.316) + (0.6)(0.280) \end{bmatrix}$$

$$X_2 = \begin{bmatrix} 207 \\ 173 \\ 120 \end{bmatrix}$$

$$X_1 = P X_0 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix} = \begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix}$$

$$X_2 = P X_1 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix} = \begin{bmatrix} 0.414 \\ 0.346 \\ 0.240 \end{bmatrix} \checkmark$$

$$X_3 = P X_2 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \begin{bmatrix} 0.414 \\ 0.346 \\ 0.240 \end{bmatrix} = \begin{bmatrix} 0.424 \\ 0.356 \\ 0.220 \end{bmatrix}$$

OR

$$X_2 = P^2 X_0 = \begin{bmatrix} 0.67 & 0.31 & 0.20 \\ 0.18 & 0.59 & 0.40 \\ 0.15 & 0.15 & 0.40 \end{bmatrix} \begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix} = \begin{bmatrix} 0.414 \\ 0.346 \\ 0.240 \end{bmatrix} \checkmark$$

AND

$$X_3 = P^3 X_0 = \begin{bmatrix} 0.557 & 0.371 & 0.280 \\ 0.238 & 0.459 & 0.420 \\ 0.175 & 0.175 & 0.300 \end{bmatrix} \begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix} = \begin{bmatrix} 0.424 \\ 0.356 \\ 0.220 \end{bmatrix}$$

$$P^2 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} \begin{bmatrix} 0.8 & 0.1 & 0.1 \\ 0.1 & 0.7 & 0.1 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} = \begin{bmatrix} 0.67 & 0.31 & 0.20 \\ 0.18 & 0.59 & 0.40 \\ 0.15 & 0.15 & 0.40 \end{bmatrix}$$

$$P^3 = P^2 P = \begin{bmatrix} 0.67 & 0.31 & 0.20 \\ 0.18 & 0.59 & 0.40 \\ 0.15 & 0.15 & 0.40 \end{bmatrix} \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix} = \begin{bmatrix} 0.557 & 0.371 & 0.280 \\ 0.238 & 0.459 & 0.420 \\ 0.175 & 0.175 & 0.300 \end{bmatrix}$$

$$\boxed{X_n = P^n X_0}$$

PROBABILITY AND STATISTICS : MARKOV CHAINS (5) THE CHAIN CONTINUED

$$X_1 = PX_0 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.40 \\ 0.24 \\ 0.36 \end{bmatrix} = \begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix}$$

$$X_2 = PX_1 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.404 \\ 0.316 \\ 0.280 \end{bmatrix} = \begin{bmatrix} 0.414 \\ 0.346 \\ 0.240 \end{bmatrix} \checkmark$$

$$X_3 = PX_2 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.414 \\ 0.346 \\ 0.240 \end{bmatrix} = \begin{bmatrix} 0.424 \\ 0.356 \\ 0.220 \end{bmatrix}$$

$$X_4 = PX_3 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.424 \\ 0.356 \\ 0.220 \end{bmatrix} = \begin{bmatrix} 0.432 \\ 0.358 \\ 0.210 \end{bmatrix}$$

$$X_5 = PX_4 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.432 \\ 0.358 \\ 0.210 \end{bmatrix} = \begin{bmatrix} 0.438 \\ 0.357 \\ 0.205 \end{bmatrix}$$

$$X_6 = PX_5 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.438 \\ 0.357 \\ 0.205 \end{bmatrix} = \begin{bmatrix} 0.442 \\ 0.355 \\ 0.203 \end{bmatrix}$$

$$X_7 = PX_6 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.442 \\ 0.355 \\ 0.203 \end{bmatrix} = \begin{bmatrix} 0.445 \\ 0.354 \\ 0.202 \end{bmatrix}$$

SAME

$$X_8 = PX_7 = \begin{bmatrix} 0.8 & 0.2 & 0.1 \\ 0.1 & 0.7 & 0.3 \\ 0.1 & 0.1 & 0.6 \end{bmatrix}\begin{bmatrix} 0.455 \\ 0.354 \\ 0.202 \end{bmatrix} = \begin{bmatrix} 0.455 \\ 0.354 \\ 0.202 \end{bmatrix}$$

STABLE DISTRIBUTION MATRIX $= \bar{X}$

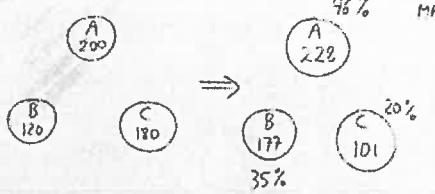

PROBABILITY AND STATISTICS : MARKOV CHAINS (8) STOCHASTIC MATRIX

$X_1 = PX_0$

$$P = \begin{array}{c} \text{FROM} \\ \begin{array}{cc} A & B \end{array} \\ \begin{bmatrix} 0.25 & 0.50 \\ 0.75 & 0.50 \end{bmatrix} \end{array} \begin{array}{c} A \\ B \end{array} \quad \text{TO} \quad X_1 = \begin{bmatrix} A \\ B \end{bmatrix}$$

$\downarrow$ ADD TO 1 STOCHASTIC

$X_1 = X_0 P$

$$P = \begin{array}{c} \text{TO} \\ \begin{array}{cc} A & B \end{array} \\ \text{FROM} \begin{array}{c} A \\ B \end{array} \begin{bmatrix} 0.25 & 0.75 \\ 0.50 & 0.50 \end{bmatrix} \end{array}$$

$\longrightarrow$ ADD TO 1 STOCHASTIC

$X_1 = [A \quad B]$

NOT STOCHASTIC

$$\begin{array}{c} \text{FROM} \\ \downarrow \begin{bmatrix} 0.9 & 0.1 \\ 0.2 & 0.8 \end{bmatrix} \end{array} \text{TO}$$

$\neq 1$

NOT STOCHASTIC

$$\begin{array}{c} \text{TO} \\ \text{FROM} \begin{bmatrix} 0.9 & 0.2 \\ 0.3 & 0.9 \end{bmatrix} \end{array}$$

$\longrightarrow \neq 1$

STOCHASTIC $P = \begin{array}{c} \text{FROM} \\ \begin{bmatrix} 0.25 & 0.50 \\ 0.75 & 0.50 \end{bmatrix} \end{array}$ TO

A STOCHASTIC MATRIX IS <u>ALSO</u> A REGULAR MATRIX

<u>IE</u> P^n $(n>1)$ HAS ONLY NON-ZERO POSITIVE ENTRIES

$$P = \begin{bmatrix} 0.25 & 0.50 \\ 0.75 & 0.50 \end{bmatrix}$$

$$P^2 = \begin{bmatrix} 0.25 & 0.50 \\ 0.75 & 0.50 \end{bmatrix} \begin{bmatrix} 0.25 & 0.50 \\ 0.75 & 0.50 \end{bmatrix}$$

$$= \begin{bmatrix} 0.438 & 0.375 \\ 0.562 & 0.625 \end{bmatrix}$$

$$P = \begin{bmatrix} 1 & 0.5 \\ 0 & 0.5 \end{bmatrix}$$

$$P^2 = \begin{bmatrix} 1 & 0.5 \\ 0 & 0.5 \end{bmatrix} \begin{bmatrix} 1 & 0.5 \\ 0 & 0.5 \end{bmatrix}$$

$$= \begin{bmatrix} 1 & 0.75 \\ 0 & 0.25 \end{bmatrix}$$